

Equipes teams.

→ material de aula.

→ plano de ensino.

Email do professor

8/15 → NÃO haverá aula.
10/15

TLC revisado

Métodos de cunhagem revisado

Raul Mura @ UNB-BR → tudo minúsculo.

15 encontros.

Encontro 1: Amostra aleatória. Distribuição amostral. 3 estimadoras.
4. propriedades das estimadoras. S. suficiência, consistência e eficiência.
Exponenciais. MVM. INF. Fisher. 10 BAYES - estimadora intervalo

modulos 1 e 2 Revisar:

tópico → quantidade pivotal

① Rohatgi, Vitay, and A. R. Ehsanes Salch.

An introduction to probability and statistics. → Seguir.

② casella - fmau para consulta

1º prazo 22 de Dezembro → todos prós de estimador
pivotal.

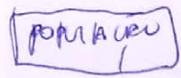
(1)

Nº haverá lista de exercícios

8.1 introdução

estimativa probabilística.

 $d_1, \dots, d_n \rightarrow$ amostra aleatória.

  exemplo da cada bombom para dependência seq. independentes

Auto-correlação ou correlação temporal.

I.I.D

formar amostras IID

$p_\theta(x) \rightarrow$ probabilidade de massa (caso discreto)

$f_\theta(x) \rightarrow$ caso contínuo

$F_\theta(x) = P_\theta(X \leq x) \rightarrow$ para o caso de função acumulado o lado é vazio.

$\Theta = (\theta_1, \dots, \theta_n)^T \in \mathbb{H}$
Espaço paramétrico

$\sim N(\mu, \sigma^2)$

Q

$$f_{\mu, \sigma^2}(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot \exp - \frac{(x-\mu)^2}{2\sigma^2}$$

$x \in \mathbb{R}$
 $\mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}^+$

$\Theta =$

Propriedades 8.2

 Resolver.

Pág 337. Livro

inferência estatística

25/10/22

$$\Theta = (\theta_1, \dots, \theta_k) \in \mathbb{H} \subset \mathbb{R}^k$$

Vetor de parâmetros

↓
espaço paramétrico

$$X = (x_1, \dots, x_n) \in \mathcal{X}$$

em que $\mathcal{X} \subseteq \mathbb{R}^n$

problema: estimar $\psi(\theta)$ por meio de $X = (x_1, \dots, x_n)$
c/ o desejando a ψ : função real.

$x_i \sim \text{Gamma}(1, \lambda)$
Forma Escala

$$E(x_i) = \frac{\lambda}{1} \quad , \quad \text{Var}(x_i) = \frac{\lambda}{1^2}$$

O livro indica utilizando estimador com regra
depois mudou pra +

$$T(x_1, \dots, x_n)$$

$$T: \mathcal{X} \rightarrow \mathbb{R}$$

qualquer função real ψ (esse prof. é um estimador).

definição de critério p/ obtenção de estatística $T(x_1, \dots, x_n)$

$$\bullet \text{ex } |T(x_1, \dots, x_n) - \psi(\theta)|$$

↓ ↓
V.A Fijo.

(3)

cx anterior

$$\left| T(x_1, \dots, x_n) - \Psi(\theta) \right|$$

↓
 v. aleatório
 ↓
 fixo

comparar critérios

P/ escolha de estimador

distorção aleatória

$$P_\theta [|T_x - \Psi_\theta| > \epsilon]$$

P/ algum ϵ → escrva p/ penalizar

$$E_\theta [|T_x - \Psi_\theta|]$$

P/ algum ϵ positivo

$$E [|T_x - \Psi_\theta|]^2 = \text{mse}_\theta(t)$$

↓
Erro quadrático médio

T'_x é "melhor" do que T_x se

$$\bullet P_\theta (|T'_x - \Psi_\theta| > \epsilon) \leq (P_\theta |T_x - \Psi_\theta| > \epsilon)$$

$$\bullet E_\theta [|T'_x - \Psi_\theta|]^n \leq E_\theta [|T_x - \Psi_\theta|]^n$$

$$\boxed{\text{var}_\theta(T'_x) + b^2 (T'_{x,\theta}) \leq \text{var}_\theta(T_x) + b^2 (T_{x,\theta})}$$

Demonstração na pg 5

(4)

$$E | T_x - \psi_\theta |^2 = \text{Var}_\theta(T_x) + b(\theta, \tau)$$

vicio
esperado

$$E | T_x - E T_x + E T_x - \psi_\theta |^2$$

$$= \text{Var}_\theta(T_x) + (E T_x - \psi_\theta)^2 + 2 E(T_x - E T_x) \cdot (E_\theta T_x - \psi_\theta)$$

0

No caso geral

$$L(t, \theta) \geq 0$$

função de perda.
VA

$$R(t, \theta) = E_\theta L(t, \theta)$$

risco = perda esperada

o melhor estimador t' é:

$$t' = \underset{\theta \in \Theta}{\text{Arg. min}} E L(t, \theta)$$

$$= \underset{\theta \in \Theta}{\text{Arg. min}} R_\theta(t, \theta)$$

$$R(t, \theta) = E_\theta L(t, \theta)$$

$$\min_{\theta \in \Theta} \int_L(t, \theta) \cdot \underset{x}{\cancel{\int f(x) dx}} \quad \text{se observado}$$

$$t' = \underset{\theta \in \Theta}{\text{Arg. min}} \int_{\mathbb{R}^n} R_\theta(t, \theta) \pi(\theta), d\theta$$

Estimador de Bayes

(5)

$$\hat{T} = \operatorname{argmin}_{\text{Estimador}} [\max R_\theta(T, \theta)]$$

min. max

Parâmetros de
forma e de escala.
variação
aleatória.

inferência Estatística 27/10/22

Consistência

$\{X_1, \dots, X_n\}$ é uma amostra qualquer. Refinada de $f(\theta)(x_1, \dots, x_n)$
com que $(x_1, \dots, x_n) \in \mathcal{X}$,

$$\theta = (\theta_1, \dots, \theta_d) \in \mathbb{R}^d$$

c) f : conhecido

Objetivo: estimar $\Psi(\theta)$

com base $T(X_1, \dots, X_n) = \underbrace{T_n}_{\text{estatística}}$

Definição Resumida

T_n é consistente
se $T_n \xrightarrow{P} \Psi(\theta)$, à medida que $n \rightarrow \infty$

$$P(|T_n - \Psi(\theta)| > \varepsilon) \rightarrow 0$$

quando $n \rightarrow \infty$

16

3.2 consistência bzj respeito a $\{T_n\}$ P/NEN

1.3 exemplo 1

X_1, \dots, X_n $\lambda.i.d.$
 $A.s.A.S$ mesma coisa
→ amostra aleatória simples

X_1, \dots, X_n iid Bernoulli (P)

Sabendo que encontra um estimador

$$\hat{T}_n = \frac{\sum_{i=1}^n X_i + 1}{n+2}$$

$$E [\hat{T}_n] = \frac{nP + 1}{n+2} \neq P$$

é viciado

$$VAR (\hat{T}_n) = \frac{n \cdot P(1-P)}{(n+2)^2}$$

$$\lim_{n \rightarrow \infty} E \hat{T}_n = \lim_{n \rightarrow \infty} \frac{nP + 1}{n+2} = P$$

Assintoticamente, \hat{T}_n não é viciado.

(7)

$$P(h(x) \geq \varepsilon) \leq \frac{E h(x)}{\varepsilon}$$

Tchebyshov.

$$P(|T_n - p(\theta)| \geq \varepsilon) \leq \frac{mse_{p(T_n)}}{\varepsilon^2} \xrightarrow{\text{P}} 0$$

onde n for $p < \infty$
não é um estimador
consistente.

de onde que $mse(T_n) < \infty$

$$MSE(T_n) = \text{Var}(T_n) + \left[\frac{n(p+1)}{n+2} - p \right]^2$$

↓ ↓
0 0

Logo, $T_n \xrightarrow{P} p$ T_n é consistente1.4 Exemplo 2 X_1, \dots, X_n iid $N(\mu, \sigma^2)$

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \xrightarrow{P} E S^2 = \sigma^2$$

$$(n-1) \frac{S^2}{\sigma^2} \sim \chi^2_{n-1} = Q_{n-1}$$

$$\begin{cases} E Q_{n-1} = n-1 \\ \text{Var } Q_{n-1} = 2(n-1) \end{cases}$$

$$\text{Var}\left(\frac{s^2}{\sigma^2} \cdot \frac{n-1}{6^2}\right) = \text{Var}(Q_n) = \frac{(n-1)^2}{6^4} \cdot \text{Var}(s^2) =$$

$$2(n-1)\text{Var}(s^2) = \frac{2 \cdot 6^4}{n-1} \xrightarrow[n \rightarrow \infty]{} 0$$

Distribuição de Zevi
ou de Pearson

$s^2 \xrightarrow{\text{P}} \sigma^2$ se $n \rightarrow \infty$

s^2 é consistente p/ σ^2

Revisar
lei dos grandes números
lei forte e lei fraca

1.5 Além da desigualdade de markov (chichychev) podemos utilizar
lei dos grandes números

Se X_1, \dots, X_n for i.i.d com $E|X| < \infty$, então

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\text{P}} \mu = E[X]$$

prova: lei forte dos grandes números de
Khintchin (pp 305-307)

Consequência:
mesmo que 2º momento $E[X^2] = +\infty$ o que significa
 $\text{Var}(\bar{X}) = +\infty$.

tem que \bar{X} é consistente p/M

inferência estatística

Caso geral: Considerar $E|X|^n < \infty$
 $n \in \mathbb{N}^+$, tendo:

$$\sum_{i=1}^n \frac{X_i}{n} \xrightarrow{\text{P}} E[X].$$

$\forall 0 < l < n$

1.6 Exercícios da seção 8.2 Pag 341 - 342

1.7 Problema Adicional

Seja X_1, \dots, X_n iid� de forma:

$$P(X > x) = \begin{cases} \left(\frac{x_0}{x}\right)^{\alpha}, & \text{p/ } x \geq x_0 > 0 \\ 0, & \text{p/ } x < x_0 \end{cases}$$

para qual(s) funções \bar{X} se a \bar{X} consiste $P/\mu = E[X]$

(10)

2. Suficiência

parametrizado/a pesquisar este termo.

2.2 X_1, \dots, X_n A.A.S (i.i.d) de $F_\theta(x)$, $\theta \in \mathbb{R}$, $x \in \mathbb{R}$

$T(X_1, \dots, X_n)$ é estatística suficiente

exemplificando

 \bar{x}_n é um estatística

$f(\theta)$ se, e só se, $X_1, \dots, X_n \mid T(X_1, \dots, X_n) = \bar{x}_n$

 \bar{x}_n é um estatística

não depender de θ então $T(X_1, \dots, X_n)$ é
estatística suficiente

+ é um caso particular de
é um estimador

obs $f_\theta(x_1, \dots, x_n)$, $X = (x_1, \dots, x_n) \in \mathcal{X}$

obs $f_\theta(x_1, \dots, x_n) = f_\theta(x_1, \dots, x_n, \bar{x})$

$$\left(X = (x_1, \dots, x_n) \in \mathcal{X} \right) = f(x_1, \dots, x_n | \bar{x}) \cdot g(\bar{x})$$

$$\bar{x} = T(x_1, \dots, x_n)$$

se T for estatística suficiente.

$$\cancel{f(x_1, \dots, x_n | \bar{x})}$$

2.2) considerando a própria Amostra como estatística.

$T(X_1, \dots, X_n) = (X_1, \dots, X_n)$ é um caso trivial e

T é suficiente.

exemplificando

$$x_1, \dots, x_n$$

$$\downarrow \quad \uparrow$$

$$x_1 \quad x_n$$

$$f(x_1, \dots, x_n | x_1, \dots, x_n) = \frac{f(x_1, \dots, x_n)}{f(x_1, \dots, x_n)} = 1 \text{ se } x_1, \dots, x_n \in \mathcal{E}$$

11

1

Ex. quando temos + parâmetro do que dados

discretizar
espaço paramétrico
à pesquisa

exs.

$$X \sim B(n, p)$$

$$n \in \{2, 3\}$$

$$p \in \left\{\frac{1}{2}, \frac{1}{3}\right\}$$

Objetivo: estimar n, p por meio de amostra de tamanho 1

$$X_1 = X \sim B(n, p) \quad n, p$$

	$(2, \frac{1}{3})$	$(2, \frac{1}{2})$	$(3, \frac{1}{2})$	$(3, \frac{1}{3})$	
0	$\frac{1}{4}$	$\frac{4}{9}$	$\frac{1}{8}$	$\frac{8}{27}$	→ observe a linha e verifica qual + prob de ser zero
1	$\frac{1}{2}$	$\frac{4}{9}$	$\frac{3}{8}$	$\frac{12}{27}$	
2	$\frac{1}{4}$	$\frac{1}{9}$	$\frac{3}{8}$	$\frac{6}{27}$	
3	$\frac{1}{2}$	0	$\frac{1}{8}$	$\frac{1}{27}$	
	1	1	1	1	

$$x=0 \rightarrow (\hat{n}, \hat{p})$$

$$T(x) = \begin{cases} (2, \frac{1}{3}), \text{ se } x=0 \\ (2, \frac{1}{2}), \text{ se } x=1 \\ (3, \frac{1}{2}), \text{ se } x=2 \text{ ou } x=3 \end{cases}$$

2.4 - exemplo 2. est. suficiente

X_1, \dots, X_n A.A.S. Bernoulli (p), $P \in (0,1)$

$T = \sum_{i=1}^n X_i$ cota constante é suficiente p/p ?

$X_1, \dots, X_n | T=t$, $p \neq t \in \{0, \dots, n\}$ independente funcionalmente de p

$$f_p(x_1, \dots, x_n | T=t) = \frac{P_p(x_1, \dots, x_n, t)}{P_p(t)}$$

$$\begin{aligned} T &= t(x_1, \dots, x_n) = \sum x_i \\ t \in \{0, \dots, n\} & \quad = \frac{P_p(x_1, \dots, x_n)}{P_p(t)} \end{aligned}$$

$$\prod_{i=1}^n \frac{p^{x_i} (1-p)^{1-x_i}}{\binom{n}{t} p^t (1-p)^{n-t}} = \frac{p^{\sum x_i} \cdot (1-p)^{n-\sum x_i}}{\binom{n}{t} p^t (1-p)^{n-t}}$$

substituir por T

$$P(x_1, \dots, x_n | T=t) = \frac{1}{\binom{n}{t}}$$

em que $t = 0, 1, \dots, n$

Logo $\sum x_i$ é suficiente p/p

1º CASO

Verificação de suficiência.

$$X_3 \mid T(X_3) = (2, \frac{1}{2}) \Rightarrow X_3 \mid X_1 = 0$$

$$X_3 + X_3 = 0$$

$$P(X_1 = 0 \mid X_3 = 0) = \frac{P(X_1 = 0)}{P(X_1 \neq 0)} = \begin{cases} 1 & \text{se } x = 0 \\ 0 & \text{se } x \neq 0 \end{cases}$$

2º CASO

$$X_3 \mid T(X_3) = (2, \frac{1}{2})$$

$$P(X_1 = 2 \mid X_3 = 1) = \begin{cases} 1 & \text{se } x = 1 \\ 0 & \text{se } x \neq 1 \end{cases}$$

3º CASO

$$X_3 \mid T(X_3) = (3, \frac{1}{2}) \Rightarrow X_3 \mid X_3 = 2 \text{ ou } X_3 = 3$$

$$P(X_1 = 2 \mid X_3 = 2 \text{ ou } X_3 = 3)$$

$$P(x \in \{2, 3\}, x = 2) = \frac{P(X_1 = 2)}{P(X_1 = 2) + P(X_1 = 3)}$$

$$= 0 \cdot 2 = 2$$

$$P(X_1 = 2 \mid X_3 = 2 \text{ ou } X_3 = 3) =$$

$$= \begin{cases} 1 & \text{se } (n, p) = (2, \frac{1}{2}) \text{ ou } (2, \frac{1}{3}) \\ \frac{3}{4} & \text{se } (n, p) = (3, \frac{1}{2}) \\ \frac{6}{7} & \text{se } (n, p) = (3, \frac{1}{3}) \end{cases}$$

Logo, $T(X_3)$ não é estatística suficiente $p(n, p)$

Suficiência

2-6) Teorema de Inferência Estatística

caso discreto

Sejam X_1, \dots, X_n sequência qualquer e $T = t(X_1, \dots, X_n)$ uma estatística para θ

T é suficiente p/ θ , se e somente se,

$$P_{\theta}(x_1, \dots, x_n) = h(x_1, \dots, x_n) \cdot g_{\theta}(t) \quad *$$

$$P_{\theta}(t) = T(x_1, \dots, x_n),$$

PROVA: (\rightarrow) Seja suficiente.

$$P_{\theta}(x_1, \dots, x_n | t) = H(x_1, \dots, x_n)$$

utilizando a propriedade *

$$P_{\theta}(x_1, \dots, x_n) = P_{\theta}(x_1, \dots, x_n, t) =$$

$$= P_{\theta}(x_1, \dots, x_n | t) \cdot f_{\theta}(t)$$

suficiente é
dependente de θ

$$= [H(x_1, \dots, x_n) \cdot f_{\theta}(t)] *$$

$$(\leftarrow) \text{ sefa } P_{\theta}(x_1, \dots, x_n) = h(x_1, \dots, x_n) \cdot g_{\theta}(t)$$

aplicando de discrete p/ discrete

$$P_{\theta}(t) = \sum_{x \in \mathbb{X} : t = T(x)} P_{\theta}(x_1, \dots, x_n) = \sum_{x \in \mathbb{X}} h(x_1, \dots, x_n) \cdot g_{\theta}(t)$$

$$P_{\theta}(x_1, \dots, x_n | \tau) = \frac{P_{\theta}(x_1, \dots, x_n)}{P_{\theta}(\tau)} \propto \ln(x_1, \dots, x_n) \cdot g_{\theta}(\tau)$$
$$\qquad \qquad \qquad \sum h(x_1, \dots, x_n) \cdot g_{\theta}(t)$$

Logo, $P(x_1, \dots, x_n | \tau)$ não depende de θ e com isso
 $T(x_1, \dots, x_n)$ é suficiente.

2.6 Teorema de fatoração

(caso discreto) $P(T(x) = \tau) = \dots$

2.7 Teorema de fatoração (caso contínuo)

- X_1, \dots, X_n sequência qualquer retirada da $f_\theta(x_1, \dots, x_n)$.
- $\theta \in \mathbb{H}$, $(x_1, \dots, x_n)' \in \mathcal{X} \subset \mathbb{R}^n$.

 $T(X_1, \dots, X_n)$ é estatística suficiente $P(\theta | T)$ se, e somente se,

$$\boxed{f_\theta(x_1, \dots, x_n) = h(x_1, \dots, x_n) \cdot g_\theta(t),}$$

em que $h(x_1, \dots, x_n) > 0$, $g_\theta(t) > 0$, $t = T(X_1, \dots, X_n) \in \overline{\mathbb{R}}$

obs: restricção p/ simplificar a prova

PROVA.

$T = T(X_1, \dots, X_n) = T_1$

$T_j = T_j(X_1, \dots, X_n) \quad j=2, \dots, n$

Lembrando inclusão de outras $n-1$ estatísticas quaisquer.

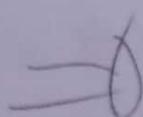
Suponha que:

$X_1 = R_1(T_1, \dots, T_n)$

$X_2 = R_2(T_1, \dots, T_n)$

$$|J| = \left| \begin{array}{c|c} \frac{\partial R_i}{\partial T_j} & \text{matriz jacobiana} \\ \hline 1 & 1 \\ 2 & 2 \\ \vdots & \vdots \\ n & n \end{array} \right|_{i,j=1, \dots, n}$$

=



(\leftarrow) seja $f_\theta(x) = h(x) g_\theta(t)$ $X = (x_1, \dots, x_n)'$

$$\int f_\theta(x) dx = \int f_\theta(\tau) d\tau, \quad \tau = (t_1, \dots, t_n)' \text{ e } t_j = T_j(x)$$

$$\int f_\theta(x) dx = h(x) \cdot g_\theta(t) \cancel{= h(x) \cdot g_\theta(t_1) dx}$$

é transformação de variável.

$$= h(t_1, \dots, t_n) \cdot g_\theta(t_1) \cdot |J| \cdot dt_1 \cdots dt_n$$

simplificando

$$= \boxed{h(\tau) g_\theta(t_1) \cdot |J| \cdot d\tau} \rightarrow \text{forma padrão via substituição de variável}$$

$$= f_\theta(\tau) = f_\theta(t_1, \dots, t_n)$$

MARGINAL(t_1):

$$f_\theta(t_1) = \int_{\mathbb{R}^{n-1}} h(t_1, \dots, t_n) \underbrace{g_\theta(t_1)}_{\text{constante}} \cdot |J| dt_2 \cdots dt_n$$

$$= g_\theta(t_1) \cdot \underbrace{H(t_1)}_{\text{não depende de } \theta}$$

Assim,

$$f_\theta(x_1, \dots, x_n | t) = f_\theta(x_1, \dots, x_n, t_1) =$$

$$\frac{f_\theta(x_1, \dots, x_n, t_1)}{f_\theta(t_1)} = \frac{f_\theta(x_1, \dots, x_n)}{f_\theta(t_1)} = \frac{h(x) \cdot g_\theta(t_1)}{H(t_1) \cdot g_\theta(t_1)}$$

$$= \frac{h(x)}{H(x)} \text{ não depende de } \theta$$

Logo $T = T(X_1, \dots, X_n)$ é suficiente p/ θ

18
2

$$I_{(x_1, \dots, x_n)}(\theta) = \begin{cases} 1, & \text{se } -\theta \leq x_{(1)} \leq x_{(n)} \leq \theta \\ 0, & \text{se c.c.} \end{cases}$$

Logo, $f_\theta(x_1, \dots, x_n)$ pode ser fatorado como

$$h(x_1, \dots, x_n) \cdot g_\theta(x_{(1)}, x_{(n)}) \quad \text{o neste caso particular é a identidade} = 1$$

$$\downarrow \quad \downarrow \\ 1 \cdot \frac{1}{(2\theta)^n} \cdot I_{x_{(1)} \leq x_{(n)}} \theta$$

de modo que

$$T(x_1, \dots, x_n) = (X_{(1)}, X_{(n)})' \text{ constitui estatística suficiente para } \theta$$

2-9 exemplo X_1, \dots, X_n iid. $N(\mu, \sigma^2)$ $\Theta = (\mu, \sigma^2)$

$$f_\theta(x) = (2\pi)^{-\frac{n}{2}} \sigma^{-n} \cdot \exp\left\{-\frac{1}{2} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2}\right\}$$

$$f_\theta(t) = (2\pi)^{-\frac{n}{2}} \cdot \sigma^{-n} \cdot \exp\left\{-\frac{1}{2\sigma^2} \left[\sum x_i^2 - 2\mu \sum x_i + n\mu^2 \right]\right\}$$

$$= h(x_1, \dots, x_n) \cdot g_\theta(t)$$

$$\text{em que } t = \left(\sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2 \right)$$

2-10. problema 8.3 (pag. 357-358)

Questões 1, 5, 7, 10, 12.

(19)
64

P/caso contínuo testando o teorema na idéia
se T for suficiente então

(\rightarrow)

$$f(x|t) = \frac{f_{\theta}(x)}{f_{\theta}(t)} = h(x)$$

Logo, $f_{\theta}(x) = h(x) \cdot f_{\theta}(t)$ posso mudar o nome
 $\downarrow =$ função

$$= h(x) \cdot g_{\theta}(t)$$

2.8 Exemplo

X_1, \dots, X_n P.A.S Unif $[-\theta, +\theta]$

$$f_{\theta}(x) = \frac{1}{2\theta} \cdot I_x(\theta)$$

$$f_{\theta}(x_1, \dots, x_n) = \frac{1}{2^n \cdot \theta^n} \prod_{i=1}^n I_{x_i}(\theta),$$

em que $I_{x_i}(\theta) = \begin{cases} 1, & \text{se } x_i \in [-\theta, \theta] \\ 0, & \text{se } x_i \notin [-\theta, \theta] \end{cases}$

$$= \frac{1}{(2\theta)^n} \cdot I_x(\theta)$$

$$I_x(\theta) = \begin{cases} 1, & \text{se } -\theta \leq x_1 \leq \dots \leq x_n \leq \theta \\ 0, & \text{c.c.} \end{cases}$$

$$x(1) = \min\{x_1, \dots, x_n\}$$

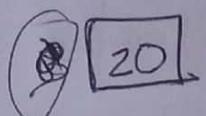
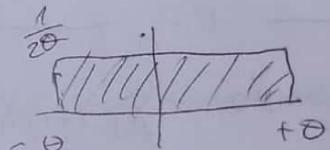
$$x(n) = \max\{x_1, \dots, x_n\}$$

$$\begin{cases} x_1 = T_1(x_1, \dots, x_n) \\ x_2 = T_2(x_1, \dots, x_n) \end{cases}$$

$$T_1 = \min$$

$$T_2 = \max$$

$$f_{\theta}(x) \begin{cases} \frac{1}{2\theta}, & \text{se } x \in [0, \theta] \\ 0, & \text{c.c.} \end{cases}$$



3. Completildade e completnude (P. 347) o livro não explica muito bem

► 3.1 Motivação

R.A.S X_1, \dots, X_n $F_\theta(x)$; $\Theta \in \mathbb{H}$, $x \in \mathbb{R}^n$; estatística T

$T(X_1, \dots, X_n)$; Seja $T_X = T(X_1, \dots, X_n)$ T. q

$$E_\theta[h(T_X)] = \psi(\theta)$$

Proporciona informação sobre $\psi(\theta)$

Questão: Dada uma estatística T_X , $\forall \theta \in \mathbb{H}$ Ligação (*) série única?

considere 2 funções h e h' , se aplicar na mesma estatística.

$$\begin{aligned} E_\theta[h(T_X)] &= \psi(\theta) \\ E_\theta[h'(T_X)] &= \psi \end{aligned} \quad \Rightarrow h(T_X) = h'(T_X) ?$$

Se isso for verdade é uma transformação unica

3.2 Definição

T_X é completa sc, $\forall \theta \in \mathbb{H}$ $E_\theta[g(T_X)] = 0 \Rightarrow g(T_X) = 0$

Porém termos probabilístico $P_\theta(g(T_X) = 0) = 1$

3.3 continuando a motivação: Assim, se T_X for completa, com respeito a motivação,

$$\Rightarrow E_\theta[h(T_X)] = E_\theta[h'(T_X)], \text{ ou seja } \cancel{E_\theta[h(T_X)]}$$

$$E_\theta[h(T_X) - h'(T_X)] = 0$$

escolhendo $g(T_X) = h(T_X) - h'(T_X)$, temos $E_\theta[g(T_\theta)] = 0$

$$\Rightarrow P_\theta(g(T_X) = 0) = 1, \text{ logo, } h(T_X) = h'(T_X)$$

22

19

3.4 Exemplo

A word.

X_1, \dots, X_n iid Bernoulli (p)

$$\bar{T}_X = X_1 + \dots + X_n \quad h(T_X) = \frac{\bar{T}_X}{n} = \bar{X} \quad E \bar{X} = \mu$$

$$E_p \left[g(T_X) \right] = E_p \left[g \left(\sum_{i=1}^n (X_i) \right) \right] = 0$$

$$\sum_{i=1}^n x_i \sim \text{Bin}(n, p) \quad E g(T_x) = \sum_{k=0}^n g(k) \cdot P(T_x = k)$$

$$= \sum_{k=0}^n g(k) \cdot \binom{n}{k} p^k (1-p)^{n-k} = (p+q)^n \cdot \sum_{k=0}^n g(k) \binom{n}{k} \left(\frac{p}{p+q}\right)^k$$

combinación de elementos ≥ 0

~~Obrigado~~, ~~obrigado~~ ~~que~~ ~~seja~~ ~~gostoso~~
para que tenhamos

$E_{\Theta} g(T_x) = 0$ & $\exists \epsilon \in [0, 1]$, a unique solution possible $\bar{g}(T_x) = 0$

3.5 Exemplos

$$X_1, \dots, X_n \text{ iid } \mathcal{U}[0, \theta], \theta > 0 \quad T_X = \max\{X_1, \dots, X_n\} = X_n$$

$$f_{\theta}(x) = \frac{1}{\theta} \cdot I_{\theta}(x), \text{ em que } I_{\theta}(x) = \begin{cases} 1, & \text{se } x \in [0, \theta] \\ 0, & \text{se } x \notin [0, \theta] \end{cases}, \quad F_{\theta}(x) = \frac{x}{\theta} \text{ para } x \in [0, \theta]$$

X_{100}, X_n ————— Ordenvariáu

$$P[X_{(n)} \leq x] = [x_1 \leq x, x_2 \leq x, \dots, x_n \leq x]$$

$\rho / x \in [0, \theta]$



Ex. 36 X_1, \dots, X_n iid $\sim N(\theta, \theta^2)$

$$f_{\theta}(x_1, \dots, x_n) = \frac{1}{(2\pi)^{\frac{n}{2}} \theta^n} \exp\left\{-\frac{1}{2\theta^2} \sum_{i=1}^n (x_i - \theta)^2\right\}$$

$$= \frac{1}{(2\pi)^{\frac{n}{2}} \theta^n} \cdot \exp\left\{-\frac{1}{2\theta^2} \left[\underbrace{\sum_{i=1}^n (x_i^2)}_{= n\theta^2} - 2\theta \sum_{i=1}^n x_i + n\theta^2 \right]\right\}$$

 $T_x = \left(\sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2 \right)$ é suficiente p/ θ

$E\left(\sum_{i=1}^n x_i\right) = n\theta$

$\text{Var}(X) = E(X^2) - E^2(X)$

$E\left(\sum_{i=1}^n x_i^2\right)$

$E X^2 = \theta^2 + \theta^2 = 2\theta^2$

$\text{Var}\left(\sum_{i=1}^n x_i\right) = n\theta^2$

$E\left[\left(\sum_{i=1}^n x_i\right)^2\right] = E\left[\underbrace{\sum_{i=1}^n x_i \sum_{j=1}^n x_j}_{\text{Ele parou}}\right] = \cancel{\left(n\theta + \theta^2\right)} \cdot \theta^2 = n(n+1)\theta^2$

$E\left[\sum_{i=1}^n x_i \sum_{j=1}^n x_j\right] = E\left[\sum_{i=1}^n x_i^2 + \sum_{i \neq j} \sum_{j=1}^n x_i x_j\right] = 2n\theta^2 + n(n-1)\theta^2$

$= 2n\theta^2 + n^2\theta^2 - n\theta^2 = n\theta^2 + n^2\theta^2$

P/ exemplo $E\left[\frac{1}{2n} \sum_{i=1}^n x_i^2 - \frac{1}{n(n+1)} \cdot \left(\sum_{i=1}^n x_i\right)^2\right]$ Existe pelo menos um x_i

função $g(T_x) = g\left(\sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2\right) \neq 0 \forall \theta$ tq $E(g(T_x)) = 0$

3.7 problema 8.3 pag. 357-359

[Questões 2, 3, 4, 6, 8 e 9] \rightarrow exercícios da prova anterior

2.10 1, 5, 7, 10, 12

Continuando Ex 3.5

Inferência Estatística

17/11/22

Fórmula

$$\frac{d}{dx} P[X_{(n)} < x] = \frac{n \cdot x^{n-1}}{\theta^n}$$

$$E[g(X_n)] = \int_0^\theta g(x) \cdot n \frac{x^{n-1}}{\theta^n} dx = 0 \quad \forall \theta > 0$$

$$= \frac{1}{\theta^n} \int_0^\theta g(x) \cdot x^{n-1} dx = 0$$

$$\frac{d}{d\theta} E[g(X_n)] = 0$$

$$= -\frac{n}{\theta} \int_0^\theta g(x) \cdot \frac{n x^{n-1}}{\theta^n} dx \times \frac{1}{\theta^n} g(\theta) n \theta^{n-1} = 0$$

$\underbrace{\qquad\qquad\qquad}_{E(g(X_n))} \qquad \qquad \qquad g(\theta) = 0 \text{ é uma solução possível}$

$\forall \theta > 0$

Exemplo 3.6

24

4- Estatística suficiente minimal

4.0 Motivação

Seja X_1, X_2, X_3 A.R.S Bernoulli (p)

$$\mathcal{X} = \left\{ \begin{array}{c} \begin{matrix} x_1 & x_2 & x_3 \end{matrix} \\ (0,0,0), (1,0,0), (0,1,0), (0,0,1) \end{array} \rightarrow A^1 \right. \\ \left. (1,1,0), (1,0,1), (0,1,1) \rightarrow A^2 \right. \\ \left. (1,1,1) \right\} \rightarrow A^3$$

$$p \in [0,1]$$

A^1 = está relacionado
ao exemplo t2
no final da
folha

Objetivo: Estimar p como $T(X_1, X_2, X_3)$

• considerar o próprio vetor de dados como estatística suficiente

ex. $T_0(X_1, X_2, X_3) = (X_1, X_2, X_3)$ } $\mathcal{X} = \{A_0, \dots, A_7\}$ $\boxed{f(X_1, X_2, X_3 | t_1) = 1}$
 $t_1 = (x_1, x_2, x_3)$ *

↓
em que cada A_j refere-se a um ponto de
*

$$\{ A_0 \cup A_1 \cup \dots \cup A_7 = \mathcal{X}$$

$$A_j \cap A_i = \emptyset$$

Seja $X_{(1)}, X_{(2)}, X_{(3)}$ uma seqüência ordenada, ou seja, $X_{(1)} \leq X_{(2)} \leq X_{(3)}$

$$T_2(X_1, X_2, X_3) = (X_{(1)}, X_{(2)}, X_{(3)})$$

$$t_2(x_1, x_2, x_3) \in \{(0,0,0), (0,0,1), (0,1,1), (1,1,1)\}$$

$$\mathcal{X} = \{A_0, A_1, A_2, A_3\}$$

Partição de \mathcal{X} induzida por \overline{T}_2 ex: $A_1 = \{(1,0,0), (0,1,0), (0,0,1)\}$

25

①

Continuação de Estatística minimal-suficiente.

4.

$$T_3 = (X_1, X_2, X_3) = X_1 + X_2 + X_3$$

$$t_3 = (x_1, x_2, x_3) \in \{0, 1, 2, 3\} \rightarrow \mathcal{X} = \{A_0, A_1, A_2, A_3\}$$

partição induzida por T_3

esta escolha foi a t_2 por conta
da estrutura dos dados

Partição formada com o menor número possível de subconjuntos
induzidos por uma estatística suficiente, é partição suficiente minimal.

4.1) X_1, \dots, X_n A.R.S e $\mathcal{U} = \{A_t : t = T(X_1, \dots, X_n)\}$

\mathcal{U} é uma partição gerada ou induzida
por $T(X_1, \dots, X_n)$

\mathcal{U} é partição suficiente para θ

se $X_1, \dots, X_n \mid A_t$ não depende de θ , ✓ At

se $X_1, \dots, X_n \mid T=t$ não depende de θ

4.2) uma partição \mathcal{U} é suficiente minimal

i) \mathcal{U} é suficiente p/ θ

ii) se \mathcal{U}^* for qualquer outra partição suficiente, então \mathcal{U}^* é uma subpartição de \mathcal{U}

26

26

4. Estatística suficiente minimal. → continuação
4.2 continuação

$$T_1(X_1, \dots, X_n) \rightarrow U_1 = \{A_0, A_1, \dots, A_7\}$$

$$T_2(X_1, \dots, X_n) \rightarrow U_2 = \{A'_0, A'_1, A'_2, A'_3\}$$

$$T_3(X_1, \dots, X_n) \rightarrow U_3 = \{A''_0, A''_1, A''_2, A''_3\}$$

(Estatística suficiente minimal é aquela com menor subconjunto do A_8)

4.3 - ~~Estatística~~ Definição: Estatística suficiente minimal é aquela que induz uma partição suficiente minimal

4.4 - Questão: inexistência de estatística suficiente pode implicar impossibilidade (inexistência) de partição induzida por uma estatística já suficiente?

4.4: não suficiência pode não induzir a uma partição de Ω ?

Voltando a motivação

$$\Omega = \{(0,0,0), (1,0,0), (0,1,0), (0,0,1), (1,1,0), (1,0,1), (0,1,1)\}$$

$$(1,1,1)$$

Considere X_1^*, X_2^* , descontando-se X_1 , ou X_2 ou X_3

$$T^*(X_1, X_2, X_3) = X_1^* + X_2^*$$

\hat{n} é suficiente p/p

27
6

4.4.

$$t^*(x_1, x_2, x_3) \in \{0, 1, 2\}$$

$$t^* = 0 \rightarrow A_0^* \{ (0,0,0), (1,0,0), (0,1,0) \} \\ \{ (0,0,1) \}$$

$$t^* = 1 \rightarrow A_1^* \{ (1,0,0), (0,1,0), (0,0,1) \\ (1,1,0), (1,0,1), (0,1,1) \}$$

$$t^* = 2 \rightarrow A_2^* \{ (1,1,0), (1,0,1), (0,1,1) \\ (1,1,1) \}$$

Como A_0^* , A_1^* , A_2^* não formam uma partição de \mathcal{X} , T^*
não induz partição de \mathcal{X}

4.5 Agora, vejemos a situação em que ocorre dados perdidos, causados por um processo Alcaforito:

$$f_j = \begin{cases} 0, & \text{Se } x_j \text{ for perdido} \\ 1, & \text{Se } x_j \text{ não for perdido.} \end{cases}$$

desconhecido
conhecido

$$x_i \sim N(\mu, 1)$$

$$f_i \sim \text{Bernoulli}(\pi)$$

no qual f_1, \dots, f_n iid $\sim \text{Bernoulli}(\pi)$

π : taxa de sucesso, f_j é v.a
nesta caso a amostra é ampliada $P(X_1, \dots, X_n, f_1, \dots, f_n)$

$$f(x_1, \dots, x_n | f_1, \dots, f_n) = \prod_{i=1}^n f(x_i)$$

realizações
de f_1, \dots, f_n

em que $f_j \in \{0, 1\}$

28

18

Continuação 4.5

$$f(x_1, \dots, x_n, \pi_1, \dots, \pi_n) = f(x_1, \dots, x_n | \pi_1, \dots, \pi_n) \cdot p(\pi_1, \dots, \pi_n)$$

$$= \left(\prod_{i=1}^n f(x_i) \right) \cdot \prod^{\sum \pi_i} (1-\pi)^{n-\sum \pi_i}$$

Verifique-se $\sum_{i=1}^n x_i \cdot \pi_i$ é suficiente p/M

O. Exercício Inferência Estatística 2411122

Seja X_1, \dots, X_n A.A.S. $N(\mu, \sigma^2)$ e considere $f_m \sim \text{BERNOULLI}(\pi)$, na qual $f_k = 1$, se X_k for observado, e $f_k = 0$ se X_k não for observado ('missing')

Defina X_1^*, \dots, X_n^* com a sequência de variáveis observáveis, tal que $f_{\theta, \pi}(x_1^*, \dots, x_n^*) = f_\theta(x_1, \dots, x_n | n_1, \dots, n_n) \cdot P_\pi(n_1, \dots, n_n)$, em que n_k é a realização de f_k , e $f_{\theta, \pi}(x_1, \dots, x_n | n_1, \dots, n_n) = \prod_{k=1}^n f_{\theta, \pi}^{n_k}(x_k)$

Mostre que

$$T(x_1, \dots, x_n) = \sum_{k=1}^n n_k X_k, \quad \left(\sum_{k=1}^n n_k \right) \xrightarrow{\text{conjunto de sucessos } n^*}$$

é suficiente para (μ, π)

4. Suficiência minimal.

Partição induzida por uma estatística suficiente T

$$f_{\theta, \pi}(x_1, \dots, x_n | t) =$$

$$= g_\theta(T(x_1, \dots, x_n)) \cdot h(x_1, \dots, x_n)$$

\downarrow

cada ponto desse vai gerar uma função que pode ser agrupado como subconjunto do espaço amostral (\mathcal{X})

$$\mathcal{U} = \{A_t : t = T(x_1, \dots, x_n) \\ x_1, \dots, x_n \in \mathcal{X}\}$$

Partição suficiente minimal possui a menor quantidade de subconjunto de partição (A_t)

30

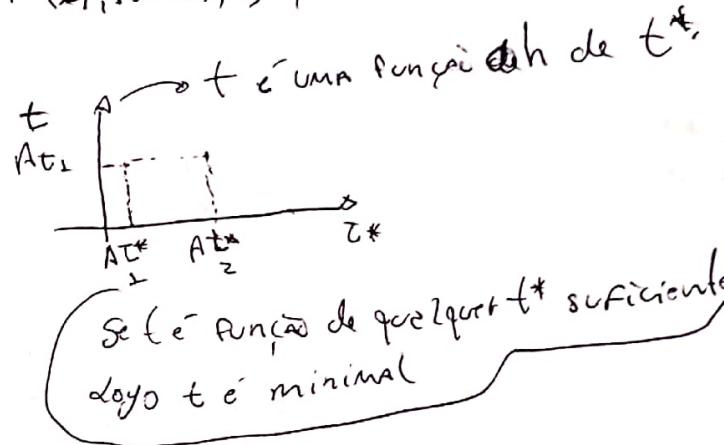
06

4.5 se $T(x)$ e $T^*(x)$ forem estatísticas suficientes, então $T(x)$ é minimal se e só se é função de $T^*(x)$, p. T^* suficiente.

partição induzida: $\mathcal{U}^* = \{A_{T^*}: t^* = T^*(x_1, \dots, x_n)\}$ por T^*

partição induzida: $\mathcal{U} = \{A_T: t = T(x_1, \dots, x_n)\}$, por T

\mathcal{U}^* é subpartição de \mathcal{U}



$$\begin{matrix} A_{T_1^*} \\ A_{T_2^*} \end{matrix} \rightarrow A_{T^*}$$

Resumo T é suficiente minimal e função de qualquer outra estatística suficiente

4.6 X_1, \dots, X_n Amostra aleatória retirada de uma densidade $f_\theta(x_1, \dots, x_n)$ e considere $T(x_1, \dots, x_n) = T$ uma estatística suficiente.

Dados dois pontos amostrais.

$$\begin{matrix} x \in \mathbb{X} \rightarrow T(x) = t \\ y \in \mathbb{X} \rightarrow T(y) = t \end{matrix}$$

se $\frac{f_\theta(x)}{f_\theta(y)}$ não depende de θ , se e só se, $T(x) = T(y)$, então

$$\begin{cases} x = \text{vetor} \\ y = \text{vetor} \end{cases}$$

T é minimal.

$$x \in \mathbb{X} \rightarrow T(x) = t \quad y \in \mathbb{X}$$

$$y \in \mathbb{X} \rightarrow T(y) = t$$

$$T(x) < T(y) \rightarrow A_T \in \mathcal{U}$$

31

Combinação 4.6

PROVA: $\frac{f_{\theta}(x)}{f_{\theta}(y)} = \frac{g_{\theta}(T(x)) \cdot h(x)}{g_{\theta}(T(y)) \cdot h(y)}$, pois T é suficiente

$$\frac{f_{\theta}(x)}{f_{\theta}(y)} = \frac{h(x)}{h(y)} \Leftrightarrow T(x) = T(y) \quad (\text{condição inicial.})$$

Considerar ~~uma~~ outra estatística suficiente $T^* = T^*(x_1, \dots, x_n)$

$$\frac{f_{\theta}(x)}{f_{\theta}(y)} = \frac{g_{\theta}^*(T^*(x))}{g_{\theta}^*(T^*(y))} \frac{h^*(x)}{h^*(y)}$$

Escolher x, y que proporcionem a mesma informação sobre θ , ~~o que~~
pelo princípio da verossimilhança, temos

$$g_{\theta}^*(T^*(x)) = C(x, y) \cdot g_{\theta}^*(x, y) \cdot g_{\theta}^*(T^*(y)), \quad \text{de modo}$$

$$\text{que } \frac{g_{\theta}^*(T^*(x))}{g_{\theta}^*(T^*(y))} = (x, y)$$

$$\text{Agora, se } T^*(x) = T^*(y), \quad \frac{f_{\theta}(x)}{f_{\theta}(y)} = \frac{h^*(x)}{h^*(y)}$$

Mas que $T^*(x) = T^*(y)$?

Dado condições iniciais, temos que $T(x) = T(y)$, logo

$$H(T^*(x)) = H(T^*(y))$$

$$T(x) \quad T(y)$$

Inferência.

Exemplo X_1, X_2, \dots, X_n A.A.S' $N(\mu, \sigma^2)$, $\Theta = (\mu, \sigma^2)$

$T = (\bar{X}, S^2)$ é suficiente para Θ

$$f_{\theta}(\underline{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} \exp \left\{ -\frac{1}{2\sigma^2} \sum (x_i - \bar{x} + \bar{x} - \mu)^2 \right\}$$

$$f_{\theta}(\underline{x}) = (2\pi)^{\frac{-n}{2}} \sigma^{-n} \cdot \exp \left\{ -\frac{1}{2\sigma^2} \left[\sum (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2 \right] \right\}$$

~~$$\frac{f_{\theta}(\underline{x})}{f_{\theta}(\underline{y})} = \exp \left(-\frac{1}{2\sigma^2} \left[\sum (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2 - \sum (y_i - \bar{y})^2 - n(\bar{y} - \mu)^2 \right] \right)$$~~

$$= (2\pi)^{\frac{-n}{2}} \sigma^{-n} \cdot \exp \left\{ -\frac{(n-1)S_x^2}{2\sigma^2} - \frac{n(\bar{x} - \mu)^2}{2\sigma^2} \right\}$$

$$\frac{f_{\theta}(\underline{x})}{f_{\theta}(\underline{y})} = \exp \left\{ -\frac{n-1}{2\sigma^2} \left[S_x^2 - S_y^2 \right] - \frac{n}{2\sigma^2} \left[(\bar{x} - \mu)^2 - (\bar{y} - \mu)^2 \right] \right\}$$

esta razão independe de $\mu, \sigma^2 \Leftrightarrow \begin{cases} S_x^2 = S_y^2 \\ \bar{x} = \bar{y} \end{cases}$

Logo $T(\bar{X}, S^2)$ é estatística suficiente e mínima.

Revisando. 4.8) suficiência mínima.

Partição suficiente mínima

$$\text{se } \frac{f_{\theta}(\underline{x})}{f_{\theta}(\underline{y})} = c(\underline{x}, \underline{y}) = \frac{h(\underline{x})}{h(\underline{y})}$$

\Updownarrow

$T(\underline{x}) = T(\underline{y})$, então $T(\underline{x})$ é suficiente mínima.

Seja $T^*(\underline{x}) = T^*$ estatística suficiente.

$$\frac{f_{\theta}(\underline{x})}{f_{\theta}(\underline{y})} = \frac{g_{\theta}(t^*(\underline{x})). h(\underline{x})}{g_{\theta}(t^*(\underline{y})). h(\underline{y})} = \frac{h(\underline{x})}{h(\underline{y})}$$

$$\mathcal{U}^* = \{A_0, A_1, \dots, A_k\}$$



$$T^*(x) = T^*(y) = t^*$$

se $\frac{f_{\theta}(\underline{x})}{f_{\theta}(\underline{y})} = c(\underline{x}, \underline{y}) \Rightarrow T^*(\underline{x}) = T^*(\underline{y}) = t^*$ disso que $\underline{x} \in \underline{y}$ estão no mesmo subconjunto da partição.

4.7) Exemplo:

Seja X_1, \dots, X_n A.A.S. retirada de uma família exponencial com

$$\theta \in \mathbb{R} \text{ e } \underline{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$$

$$f_{\theta}(x_i) = \exp\{A(\theta) \cdot B(x_i) + C(\theta) + D(x_i)\}$$

$$f_{\theta}(\underline{x}) = \exp\{A(\theta) \sum B(x_i) + n C(\theta) + \sum D(x_i)\}$$

$$= \underbrace{\exp\{A(\theta) T(\underline{x}) + n C(\theta)\}}_{g_{\theta}(T(\underline{x}))} \cdot h(\underline{x})$$

$$g_{\theta}(T(\underline{x})) \cdot h(\underline{x})$$

Logo $T(\underline{x})$ é suficiente para θ . Θ

34



$$\frac{f_0(x)}{f_0(y)} = \exp\left\{ A(\theta) \underbrace{[T(x) - T(y)]}_{=0} \right\} \cdot \frac{h(x)}{h(y)}$$

= 0 (remos)

$\frac{h(x)}{h(y)}$

corr' p/ tā

$$= \frac{h(x)}{h(y)} \Leftrightarrow T(x) = T(y)$$

Assim, $T(x)$ é estatística suficiente e minimal.

$T(x)$ é suficiente e completa?

Anovar o ex 4.7 p/ provar
completa.

Obs: Caso eu quero provar que seja minimal
posso utilizar o conceito de completo
uma estatística suficiente e completa
é automaticamente minimal.

$$E g(T(x)) = 0 \Rightarrow \underbrace{g(T(x))}_{C/Prob} = 0$$

$$E g(T(x)) = \int_{\mathbb{R}^n} g(T(x)). \exp\left\{ A(\theta) \underbrace{\sum_{i=1}^n \beta(x_i)}_{>0} \right\} \cdot \exp\left\{ n.c(\theta) \right\} \cdot h(x) \cdot dx$$

fatoração de $e^{x^T \theta}$.

$$= \int_{\mathbb{R}^n} \exp\left\{ A(\theta) \sum_{i=1}^n y_i \right\} \exp\left\{ n.c(\theta) \right\} \cdot g(T(y)) \cdot h(y) \underbrace{\left| J \right|_y}_{H(y)} dy$$

$$\text{seja } H(y) = \underbrace{H^+(y)}_{>0} - \underbrace{H^-(y)}_{>0}$$

$$= \exp\left\{ n.c(\theta) \right\} \int_{\mathbb{R}^n} \cancel{\exp\left\{ A(\theta) \cdot \sum_{i=1}^n y_i \right\}} \quad \text{cancelado q/ depois}$$

$$= \exp\left\{ n.c(\theta) \right\} \int_{\mathbb{R}^n} e^{\cancel{A(\theta) \sum_{i=1}^n y_i}} \cdot \left[\underbrace{H^+(y)}_{>0} - \underbrace{H^-(y)}_{>0} \right] dy$$

Transformada da
Leplace. Olhar
depois

Distribuição a priori p/ inferência \rightarrow

35

Continuação do exemplo 4.7

$$\Rightarrow \exp[n \cdot c(\theta)] [L H^+(y) - L H^-(y)] = 0$$

(transformada de Laplace)

$$L H^+(y) = L H^-(y) \rightarrow H^+ = H^-$$

$$H^+ - H^- = g(T^*) \cdot \ln^* \cdot |J| = 0$$

$$= (g^+ - g^-) \text{ Logo, } g^+ = g^- \text{, } g = 0$$

então $T(x) = \sum_{i=1}^n B(x_i)$, é suficiente, completa e minimal.

4.8. Exemplo. X_1, \dots, X_n A.A.s retirados de uma distribuição de touchard (λ, δ) na forma:

$$P_{(\lambda, \delta)}(x) = \frac{\lambda^x (x+1)^{\delta}}{x! \tau(\lambda, \delta)}, \lambda > 0, \delta \in \mathbb{R}, x \in \{0, 1, \dots\} \text{ e } \tau(\lambda, \delta) = \sum_{k=0}^{\infty} \frac{\lambda^k (k+1)^{\delta}}{k!}$$

Função de normalização

$$\begin{cases} \theta = \ln \lambda \\ \lambda = e^{\theta} \end{cases} \quad \lambda > 0$$

$$\tau(\lambda, \delta) = \sum_{k=0}^{\infty} \frac{\lambda^k (k+1)^{\delta}}{k!}$$

Logo é f(m)

$$P_{(\lambda, \delta)}(x) = \exp \left\{ \ln \lambda \frac{\lambda^x (x+1)^{\delta}}{\tau(\lambda, \delta)} \right\}$$

distribuição marginal

$$= \exp \{ x \cdot \ln \lambda + \delta \cdot \ln(x+1) - \ln \tau(\lambda, \delta) \}$$

$$P_{(\lambda, \delta)}(x) = \exp \left\{ \ln \lambda \cdot \sum_{i=1}^n x_i + \delta \cdot \sum_{i=1}^n \ln(x+1) + \sum_{i=1}^n \ln x_i! - n \cdot \ln \tau(\lambda, \delta) \right\}$$

$$P_{(\lambda, \delta)}(x) = \exp \{ A(\lambda, \delta) \cdot B(x) + C(\lambda, \delta) + D(x) \}$$

36

7

8

Continuação do ex. 4.8.

$$A(\lambda, \delta) = [\ln \lambda, \delta] \quad B(x) = \left[\sum_{i=1}^n x_i, \sum_{i=1}^n \ln(x_{i+1}) \right]$$

$$P_{\lambda, \delta}(x) = g_{\lambda, \delta}(B(x)) \cdot h(x)$$

$$\exp - \sum_{i=1}^n \ln x_i / \delta$$

Logo

$$B(x) = \left[\sum x_i, \sum \ln(x_{i+1}) \right]'$$

Constitui estatística.

Suficiente $p(\lambda, \delta)$, completa e mínima

5 | Ancilariade

s.s. X_1, \dots, X_n A.A. se retirada de $f_\theta(x)$, se $R(X_1, \dots, X_n)$ não depende de θ então R é uma estatística ancílare

s.s. exemplo

X_1, \dots, X_n A.A. $\sim N(\mu, 1)$

$$\bar{X} = \frac{1}{n} \sum x_i \sim N(\mu, \frac{1}{n})$$

$$S^2 = \frac{1}{n-1} \sum \frac{(x_i - \bar{x})^2}{n-1}, (n-1) \frac{S^2}{6^2} \sim \chi_{(n-1)}^2$$

segundo prof. S^2 independente de \bar{X} ?

$$\sum \frac{(x_i - \bar{x})^2}{6^2} \text{ - erro padrão}$$

Logo S^2 é estatística ancílare.

S.3. Amplitude

$$\text{Amplitude} = \frac{x(n) - x(1)}{\text{MAX} - \text{MIN}}$$

\bar{x} e s^2 são independentes?

$$f_{\bar{x}, s^2}(\bar{x}, s^2) = f_{\bar{x}}(\bar{x}) f_{s^2}(s^2) \quad \text{ou utilizar a forma de passo}$$

S.3 Base: se $T(x)$ for estatística suficiente e completa,
e se $R(x)$ for uma estatística privilígiada, então $T(x), R(x)$
são independentes.

S. Estatística Analítica5.3 Teorema de Basu.

Seja $\tilde{X} = (X_1, \dots, X_n)$ uma A.A.S. Retirada de uma distribuição $F_\theta(x)$, $x \in \mathbb{R}$, $\theta \in \Theta$. Se $T(\tilde{X})$ for estatística suficiente completa $P(\Theta)$, se $R(\tilde{X})$ for uma estatística analítica, então $T(\tilde{X}) \subset R(\tilde{X})$ são independentes.

Prova: suponha $\theta \in \Theta$, $T(\tilde{x}) \in R(\tilde{x}) \in \mathbb{R}$; temos suposição que é completa logo $E[\cdot] = 0$

$$f_R(r) = \int_{\mathbb{R}} f_{R|T}(r|t) f_T(t) dt$$

$$f_R(r) - \int_{\mathbb{R}} f_{R|T}(r|t) f_T(t) dt = 0$$

$$\int_{\mathbb{R}} f_T(t) dt \cdot f_R(r) - \int_{\mathbb{R}} f_{R|T}(r|t) f_T(t) dt = 0$$

$$\int_{\mathbb{R}} [f_R(r) - f_{R|T}(r|t)] \cdot f_T(t) dt = 0 \quad \text{D} \text{pois A.U.A em questão é } T$$

$$- E_\theta [f_R(r) - f_{R|T}(r|T)] = E_\theta [g(T)] = 0$$

por suposição inicial
de completude.

(Como T é completa, $P[g(T) = 0] = 1$, logo)

$$f_R(r) = f_{R|T}(r|t), \forall t \in \mathbb{R}, \text{ ou seja, } f_{R|T}(r|t) = f_R(r) \cdot f_T(t), \text{ logo}$$

T, R são independentes

| 39 |

5.4 X_1, \dots, X_n A.A.S $\rightarrow N(\mu, 1)$, com X, Y independentes.
 Y_1, \dots, Y_n A.A.S $\rightarrow N(\mu, 1/n)$

$$\text{SEJAM } T(X, Y) = \bar{X} + \bar{Y} = N(2\mu, \frac{2}{n})$$

$\downarrow \mu \downarrow \frac{1}{n}$ $\downarrow \mu \downarrow \frac{1}{n}$

$$R(X, Y) = \bar{X} - \bar{Y} \sim N(0, \frac{1}{n}) \text{ estatística anúlao}$$

"por força bruta", vamos verificar que $R \perp T$ sejam independentes
 como são independentes partidamente da distribuição conjunta.

$$f_{T, R}(t, r) = f_T(t) f_R(r) \stackrel{\text{def}}{=} \cancel{\frac{1}{2\pi \frac{1}{n}}} \cdot \exp\left(-\frac{1}{2} \frac{(t-\mu)^2}{\frac{2}{n}} - \frac{1}{2} \frac{(r-\mu)^2}{\frac{1}{n}}\right)$$

$$\text{u. u. u. u. u.} = \frac{1}{2\pi \frac{1}{n}} \cdot \exp\left(-\frac{n}{2} \left[(\bar{x}-\mu)^2 + (\bar{y}-\mu)^2 \right] \right)$$

$$\begin{cases} t = \bar{x} + \bar{y} \\ r = \bar{x} - \bar{y} \end{cases} \rightarrow \begin{cases} \bar{x} = \frac{t+r}{2} \\ \bar{y} = \frac{t-r}{2} \end{cases}$$

~~$\frac{d\bar{x}}{dt} \quad \frac{d\bar{x}}{dr}$~~ $J = \begin{vmatrix} \frac{d\bar{x}}{dt} & \frac{d\bar{x}}{dr} \\ \frac{d\bar{y}}{dt} & \frac{d\bar{y}}{dr} \end{vmatrix} = \begin{vmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{vmatrix} = -\frac{1}{2}$

$$f_{R, T}(r, t) = \frac{1}{2\pi \frac{1}{n}} \cdot \exp\left(-\frac{n}{2} \left(\frac{t+r}{2} - \mu \right)^2 - \frac{n}{2} \left(\frac{t-r}{2} - \mu \right)^2\right)$$

$$= |J| \frac{1}{2\pi \frac{1}{n}} \cdot \exp\left(-\frac{n}{2} \cdot \frac{(t+r-2\mu)^2}{4} - \frac{n}{2} \cdot \frac{(t-r-2\mu)^2}{4}\right)$$

$$= \frac{n}{4\pi} \cdot \exp\left(-\frac{n}{2 \cdot 2} (t-2\mu)^2 - \frac{n}{2 \cdot 2} r^2\right)$$

$$= \frac{1}{\sqrt{2\pi \cdot 2/n}} \cdot \exp\left(-\frac{1}{2} \frac{(t-2\mu)^2}{2/n}\right) \times \frac{1}{\sqrt{2\pi \cdot 2/n}} \cdot \exp\left(-\frac{1}{2} \frac{r^2}{2/n}\right)$$

$$= f_T(t) \cdot f_R(r)$$

40
62

5.4 Continuação do Ex. pelo teorema de Basu,
 sabendo que $\bar{X} + \bar{Y}$ é suficiente completo p/M como $\bar{X} - \bar{Y}$ é anular
 então T e R são independentes.

5.5 Sugestão dos exercícios Problema 8.3

Ex. 30, 31, 13, 15, 18, e 19.

Exercício 1 8.2 $P[|T_n - \theta| > \varepsilon] \rightarrow 0$ \rightarrow erro de estimativa
 se T_n for consistente p/ θ , e se $|T_n - \theta| \leq A < \infty$, então $T_n \xrightarrow{\text{q.d.o}} \theta$

$$E \left[\frac{(T_n - \theta)^2}{> 0} \right] \xrightarrow{\text{q.d.o}} 0$$

se X for v.a contínua não negativa então $E X = \int_{\mathbb{R}} x f_x(x) dx = \int_{\mathbb{R}} P(X > x) dx$

$$E \left[(T_n - \theta)^2 \right] = \int_0^\infty P[|T_n - \theta| > \varepsilon] dx \quad \varepsilon = \sqrt{\varepsilon} \rightarrow \varepsilon^2 = \varepsilon$$

$$= 2 \int_0^A \varepsilon P[|T_n - \theta| > \varepsilon] d\varepsilon + 0 \leq \int_0^A A \cdot P[|T_n - \theta| > \varepsilon] d\varepsilon$$

$$P(|T_n - \theta| \leq A) = 1$$

$$P(|T_n - \theta| > A) = 0$$

$$0 \leq \varepsilon \leq A$$

$$\theta \leq \int_0^A A \cdot P[|T_n - \theta| > \varepsilon] d\varepsilon$$

10/12/22
 174,00
 1772,98
 Dezembro

- Foi predominante até o final de 2010
- para distribuições independentes entre proba conjunta e produtório das marginais.
- procedimento frequentista.

A.A.5

Definição: Qualquer função da amostra que não depende do parâmetro é denominada Estatística ex: min; max $T_1 = \bar{x}$, $\left(\frac{1}{n} \sum x_i\right)$ - função de A amostra. $T_2(x) = S^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$

em geral se não depende do parâmetro fizemos que estas estatísticas também são amostra Aleatórias.

Estimador: Qualquer estatística, ou seja, função da amostra que Assuma valores em $\hat{\theta}$ é um estimador $\hat{\theta}$ para o parâmetro

 θ

→ para encontrar

$$E(QM(\hat{\theta})) = VPR(\hat{\theta}) + \beta^2(\hat{\theta})$$

em que $\beta(\hat{\theta}) = E(\hat{\theta}) - \theta$ é o risco do estimador

Exercícios - secção 8.1

Pecorin
informática
1 Experimento
velocidade
de luz.

introdução sobre estimação pontual paramétrica

ex. 8.2 todos exercícios

[Definição de suficiência] - EX 8.1 secção 8.3 1, 5, 7, 10, 12

8.3 - complete - questões 2, 3, 4, 6, 8, 9

8.

42

D [James enviar email p/ccc] → Data Academy

Desigualdade de Cramer-Rao possibilita verificar se um estimador é ou não suficiente, porém não é um método de construção de estimadores ótimos.

ex. considere X_1, X_2, X_3 A.A. tomados em θ

$$X = \{(0,0,0), (1,0,0), (0,1,0) \\ (0,0,1), (1,1,0), (1,0,1) \\ (0,1,1), (1,1,1)\}$$

Seja $T(X_1, X_2, X_3) = X_1 + X_2 + X_3$ uma função de A.A. que retorna valores tais que

$$t(X_1, X_2, X_3) = X_1 + X_2 + X_3 = \{0, 1, 2, 3\}$$

→ para ser estatística suficiente NÃO se deve ter perca de informação a respeito do parâmetro. Assim o princípio da suficiência diz que uma estatística $T = T(X_1, \dots, X_n)$ pode extrair toda informação que a amostra $A. X_1, \dots, X_n$ contém sobre θ então digemos que T é suficiente para θ

Definição: Digemos que $T = T(x) = T(x_1, \dots, x_n)$ é suficiente p/ θ , qd o a distribuição condicional de $X_1, \dots, X_n | T = \text{suficiente}$ for independente do parâmetro (θ)

6.6. Exemplo/ Existente de "dois" ou mais estimadores não viésados.

$X_1, \dots, X_m \sim \text{poisson}(\lambda) \rightarrow \text{somas de poisson} = \text{poisson}$

$$\bar{X} = \sum_{i=1}^n X_i = T_1(\underline{X}), \quad E T_1(\underline{X}) = \lambda$$

$$S_2 = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{n-1} = T_2(\underline{X}), \quad E T_2(\underline{X}) = \lambda$$

$\lambda = \begin{cases} \text{s. acidente / dia} \\ \text{s.(acidente / dia)}^2 \\ \text{numeros normais são} \\ \text{iguais para os} \\ \text{grupos são diferentes.} \end{cases}$

$$T_3(\underline{X}) = \pi T_1(\underline{X}) + (1-\pi) T_2(\underline{X}) \text{ com } \pi \in [0, 1]$$

temos que $E T_3(\underline{X}) = \lambda \forall \pi \in [0, 1]$

6.7 Considere $E T_0(\underline{X}) = \theta_0$; ~~$E T_1(\underline{X}) = \theta_0$~~ , em que $\theta_0 \in \Theta$

$\text{VAR}(T_0) < \text{VAR}(T_1)$, significa que T_0 é, ~~localmente~~ estimador ~~baixista~~
não viésado de mínima variação, ~~& T_0~~

6.8 Para $E T_0(\underline{X}) = \theta$ e $E T_1(\underline{X}) = \theta$, $\forall \theta \in \Theta$

$\text{VAR}(T_0) \leq \text{VAR}(T_1)$, $\forall T_1$, significa que T_0 é estimador não viésado
uniformemente de mínima variação. (ENVVUMV)

Ex utilizando séries temporais

$$\hat{Y}_n = \sum_{k=1}^n \theta^k \epsilon_k \quad (\theta |<1) \quad \text{Var}(\epsilon_k) = \sigma^2$$

$$\text{Var}(\bar{Y}_n) = \sigma^2 \sum_{k=1}^n (\theta^k)^2$$

$$\lim_{n \rightarrow \infty} \text{Var}(\bar{Y}_n) = \sigma^2 \cdot \frac{\theta^2}{1-\theta^2} \quad \text{não basta p/ ser unbiased}$$

$$6.1 \boxed{E_\theta T(\tilde{x}) = \Psi(\theta)}$$

Vício negativo = subestimar

Em que $\tilde{x} = (x_1, \dots, x_n)'$ e T é uma função apropriada

$$6.2 b_\theta(T, \Psi) = E_\theta T(\tilde{x}) - \Psi(\theta) \quad \text{vício}$$

6.3 Exemplo: variância amostral

$$\hat{s}_2^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \quad E(s_2^2) = \sigma^2 \quad (\text{variancia populacional})$$

Mas, como $\text{VAR}(s^2) = E(s^2) - E^2(s) = \sigma^2 - E^2(s) > 0$, tem $E(s^2) < \sigma^2$

$$b(s^2, \sigma^2) < 0$$

Nem sempre o estimador é viciado existe

$$6.4. \text{ Exemplo de (inexistência) } \text{VAR } X = P(1-P) = P^2$$

$X \sim \text{Bernoulli}(p)$, $p \in (0, 1)$, obter $T(x)$ t.q. $E T(x) = p^2 = \Psi(p)$

$$\begin{aligned} T(x) &= \begin{cases} T(0), & \text{c} / 1-p \\ T(1), & \text{c} p \end{cases} \\ &\text{verificar se isso} \\ &\text{é possível} \end{aligned}$$

$$T(x) = \begin{cases} T(0), & \text{c} / 1-p \\ T(1), & \text{c} p \end{cases}$$

$$E T(x) = (1-p) \cdot T(0) + p T(1) = p^2$$

$$p^2 + p [T(1) - T(0)] + T(0) = 0 \quad \forall p \in (0, 1)$$

$$e^a = \sum_{k=0}^{\infty} \frac{a^k}{k!}$$

Logo não é possível obter $T(x)$ t.q. $E T(x) = p^2$

6.5. Exemplo (não adequação)

$X \sim \text{Poisson}(\lambda)$, $EX = \lambda > 0$, suponha que tenhamos $T(x) = (-2)^x$

$$ET(x) = \sum_{k=0}^{\infty} \frac{e^{-\lambda} \lambda^k (-2)^k}{k!} = e^{-\lambda} \cdot e^{-2\lambda} = e^{-3\lambda}$$

$$ET(x) = e^{-3\lambda} = \Psi(\lambda)$$

$$T(x) \text{ não é viciado } \rho / e^{-3\lambda}$$

45

①

6.9 Considere $T(\bar{x})$, tq $ET(\bar{x}) = \theta$, $\text{VAR } T(\bar{x}) < \infty$,

se, seja $V(\bar{x})$, tq; $EV(\bar{x}) = 0$ e $\text{VAR } V(\bar{x}) < \infty$,

($V(\bar{x})$) é um tipo de estatística angular? para qualquer $V(\bar{x})$ nessas condições;

$T(\bar{x})$ é ENVUMV, se e só se, $E[V(\bar{x}) \cdot T(\bar{x})] = 0, \forall \alpha, \forall V(\bar{x})$

PROVA: ~~→~~ Pelo Absurdo suponha que $E[V(\bar{x}) \cdot T(\bar{x})] \neq 0$ ~~forall~~

Sigre $T^*(\bar{x}) = T(\bar{x}) + \alpha \cdot V(\bar{x})$, de modo que

$$ET^*(\bar{x}) = E[T(\bar{x}) + \alpha \cdot V(\bar{x})] = \theta$$

T^* é viável.

$$\text{VAR } T^*(\bar{x}) = \text{VAR } T(\bar{x}) + \alpha^2 \text{VAR}(\bar{x}) + 2 \cdot \alpha \cdot \text{cov}[T(\bar{x}), V(\bar{x})]$$

→ Vamos mostrar o Absurdo p/uma escolha particular. Se α

$$\text{Sigre } \alpha = -\frac{\text{cov}[T(\bar{x}), V(\bar{x})]}{\text{VAR}(V(\bar{x})}, \text{ daí temos.}$$

$$\text{VAR } T^* = \text{VAR } T(\bar{x}) + \frac{\text{cov}^2 [T(\bar{x}), \text{VAR}(\bar{x})]}{\text{VAR}(V(\bar{x}))} - 2 \cdot \frac{\text{cov}^2 [T(\bar{x}), V(\bar{x})]}{\text{VAR}(V(\bar{x}))}$$

$$\text{VAR } T^*(\bar{x}) = \text{VAR } T(\bar{x}) - \frac{\text{cov}^2 [T(\bar{x}), V(\bar{x})]}{\text{VAR}(V(\bar{x}))} \quad \text{ou sigre,}$$

$$> 0 \quad > 0 \quad > 0$$

$$\text{VAR } T^*(\bar{x}) < \text{VAR } T(\bar{x})$$

O que é um \rightarrow contradição

Logo, $E[V(\bar{x}) \cdot T(\bar{x})] = 0$, $T(\bar{x})$ é ENVUMV

96

8

Continuação 6.9

Seja T t.q. $E[V(\tilde{x}) \cdot T(\tilde{x})] = 0$ e considere T^* t.q. $ET^* = \theta$, tome $V(\tilde{x}) = T(\tilde{x}) - T^*(\tilde{x})$.

$$E[V(\tilde{x}) \cdot T(\tilde{x})] = E[(T - T^*) \cdot T] = 0$$

$$= E[T^2] - E[T^* \cdot T] = 0$$

$$\underbrace{E(T^2) - \theta^2}_{\text{Var}(T(\tilde{x}))} = E[T^* \cdot T] - \theta \cdot \theta$$

$$\text{Var}(T(\tilde{x})) = \text{Cov}(T(\tilde{x}), T^*(\tilde{x})) \quad \text{com isso, } \text{Var}(T(\tilde{x})) \leq \text{Var}(T^*)$$

~~$T(\tilde{x}) \in VUMV$~~

$$\left| \text{Cov}(T(\tilde{x}), T^*(\tilde{x})) \right|^2 \leq \text{Var}(T) \cdot \text{Var}(T^*)$$

$$\frac{(\text{Var } T(\tilde{x}))^2}{\text{Var } T(\tilde{x})} \leq \text{Var}(T^*)$$

Com isso, $\text{Var}(T(\tilde{x})) \leq \text{Var}(T^*)$

$T(\tilde{x})$ é EP.VUMV

47

67

6-

Inferencia Estatística

08/12/22

* Relembrando a última Aula

6.9. X_1, \dots, X_n A.A.S' $F(x)$, $E[T(x)] = 0$, $\text{Var}[T(x)] < \infty$

$$E[V(x)] = 0, \quad \text{Var}[V(x)] < \infty, \quad V(x) \neq 0$$

$T(x)$ é ENVOLVIDO P/0 se e só se $E[V(x) \cdot T(x)] = 0$

6.10. $\exists!$ ENVOLVIDO P/0

3! -> se existe

PROVA: Suponha que existe que $E[T^*(x)] = E[T(x)] = 0$ e Var

$$\text{Var}[T^*(x)] = \text{Var}[T(x)] < \infty$$

Considera $V(x) = T^*(x) - T(x)$, $E[V(x)] = E[T^*(x) - T(x)] = 0$

$$E[V(x) \cdot T(x)] = \text{se}$$

$$E[V(x) \cdot T(x)] = E[(T^* - T) \cdot T] = E[T^*T - T^2] = E[T^*T] - E[T^2] = 0$$

$$E[T^*T] = E[T^2]$$

$$E[T^*T] - 0^2 = E[T^2] - 0 \quad (\text{ET})^2$$

$$\text{cov}(X, Y) = E(XY) - E(X) \cdot E(Y)$$

$$\text{cov}(T^*, T) = \text{Var}(T) = \sqrt{\text{Var}(T)} \cdot \sqrt{\text{Var}(T^*)} = \sqrt{\text{Var}(T)} \cdot \sqrt{\text{Var}(T^*)}$$

$$f_{T^*, T} = \frac{\text{cov } T^*, T}{\sqrt{\text{Var} T^* \text{Var} T}} = 1 \Rightarrow T = T^*$$

48

1

6. Estimador Único

Migon e Gamarman - o que é estatística.

6.1. Teorema de Rao-Blackwell

Sejam $H(x)$ e $T(x)$ tais que $E[H(x)] = \theta$ e $T(x)$ estatística suficiente para θ .

Então $E[H(x) | T(x)]$
(variável aleatória)

é estimador não viésado de θ .

ii) de mínima variância.

PROVA: i. $E[E(H|T)] = E[H] = \theta$

$$E[H|T] = \iint_{\mathbb{R}^2} h \cdot f(h, t) dh dt$$

$$\iint h \cdot f(ht) / t dt dh$$

ii $E[\text{VAR}(H|T)] = E[E(H^2|T) - E^2(H|T)] =$

$$E[E(H^2|T)] - E[E^2(H|T)] = \underbrace{E(H^2) - E^2(H)}_{\text{VAR}(H)} - E[E^2(H|T)] + E^2(H)$$

$$= \text{VAR}(H) - E[E^2(H|T)] + (E[E(H|T)])^2$$

$\therefore \text{VAR}(H) - \text{VAR}[E(H|T)] \geq 0$

Logo $\text{VAR}[E(H|T)] \leq \text{VAR}(H) \forall \theta$ ENQUANTO

49

Sejam $H(\underline{x})$ e $T(\underline{x})$ tais que

Prova: Sejam H_1 e H_2 estimadores tais que $E(E(H_1|T)) = \theta$ e $E(E(H_2|T)) = \theta$

$$\text{então } E[H_1 - H_2|T] = 0$$

$$E[E(H_1|T) - E(H_2|T)] = 0$$

$$E[g(T)] = 0 \Rightarrow g[E(H_1|T) - E(H_2|T)] = 1$$

6.13 Exemplo

X_1, \dots, X_n A.A.S. $\sim N(\mu, 1)$ obter ENVVUMV p.m
sabemos que $T(\underline{x}) = \sum_{i=1}^n x_i$ é suficiente $H(\underline{x}) = \bar{x}$ é NÃO viciado para μ .

$$E[H(\underline{x})|T(\underline{x})] = E[\bar{x} | \sum_{i=1}^n x_i]$$

CURVA de Regressão sob normalidade.

$$E[H(\underline{x})|T(\underline{x})] = \beta_0 + (\beta_1) T(\underline{x})$$

$$\begin{aligned} \beta_0 &= f_{H,T} \frac{\sqrt{\text{Var}[H(\underline{x})]}}{\sqrt{\text{Var}[T(\underline{x})]}} \\ &= \frac{1}{n} \end{aligned}$$

$$\begin{aligned} \text{cov}(H, T) &= E(H \cdot T) - E[H] \cdot E[T] \\ &= E\left[X, \sum_{i=1}^n x_i\right] - E[\bar{x}] \cdot E\left[\sum_{i=1}^n x_i\right] \\ &= E\left[X^2 + \sum_{i=1}^n x_i \cdot x_i\right] - n\mu^2 \\ &= 1 + \mu^2 + (n-1) \cdot \mu^2 - n\mu^2 = 1 \end{aligned}$$

.....

$$E[E(H|T)] = \beta_0 + \beta_1 \cdot E[T]$$

μ

$$\mu + \beta_0 + \frac{1}{n} \cdot n \cdot \mu \rightarrow \beta_0 = 0$$

Logo $E(H_2|T) = \frac{1}{n} = \frac{1}{n} \sum x_i = \bar{x}$

Logo c². ENVVUMV → ACABOU AQUI
 \bar{x} é UNICO pois, pois $\sum x_i$ é suficiente e completo.



Inferência estatística

6.14) Observação de $T(x)$ suficiente
 $H(x)$, estatística é visada.

Se $H(x) = H(T(x))$, então $H(x)$ é estatística EPVUM

$$E[H(x)|T(x)] = \underbrace{E[H(T(x))|T(x)]}_{\text{Redundante}}$$

$$= H[T(x)]$$

Assunto da prova p/ c seção 8.4.

problemas 8.4, 7, 8, 9, 10, 25, 26

51

13/12/22

①

7. Limite inferior de Cramer - Rão - Fréchet.

$$\text{cov}(x,y) = E(x \cdot y) - E(x) \cdot E(y)$$

Seja X_1, \dots, X_n uma amostra retirada de uma densidade constante $f_\theta(x_1, \dots, x_n)$, $\theta \in \mathbb{R}$, e $\bar{x} = (x_1, \dots, x_n)^T \in \mathbb{R}^n$. + q $f_\theta(x) > 0$

Objetivo: Dado um estimador $T(\bar{x})$ $\boxed{T \text{ q } E_\theta T(\bar{x}) = \psi(\theta)},$

encontre o um limite inferior para $T(\bar{x})$, ou seja, $\text{VAR}_\theta T(\bar{x}) \geq g(\theta)$

Considere $E_\theta T(\bar{x}) = \psi(\theta)$

$$\frac{d}{d\theta} E_\theta T(\bar{x}) = \frac{d}{d\theta} \cdot \psi(\theta) = \psi'(\theta), \text{ em que } \psi \text{ é derivável}$$

$$\frac{d}{d\theta} \int_{\mathbb{R}^n} T(\bar{x}) f_\theta(\bar{x}) d\bar{x} = \int_{\mathbb{R}^n} T(\bar{x}) \frac{d}{d\theta} f_\theta(\bar{x}) d\bar{x}$$

$$(*) \int_{\mathbb{R}^n} T(\bar{x}) \cdot \frac{d}{d\theta} \ln f_\theta(\bar{x}) \cdot f_\theta(\bar{x}) d\bar{x}$$

$$= E_\theta \left[T(\bar{x}) \cdot \underbrace{\frac{d}{d\theta} \ln f_\theta(\bar{x})}_{\text{Score de Fisher.}} \right] = \star \underbrace{\text{Cov}_\theta \left[T(\bar{x}), \frac{d}{d\theta} \ln f_\theta(\bar{x}) \right]}_{\text{este resultado é usado para}} \star$$

Daremos obter $E \left[\cdot \cdot \frac{d}{d\theta} \ln f_\theta(\bar{x}) \right] = 0 \rightarrow \star$ Voltando aplicando este à base do passo 3 então temos

$$\int_{\mathbb{R}^n} f_\theta(\bar{x}) d\bar{x} = 1 \cdot \frac{d}{d\theta} \int_{\mathbb{R}^n} f_\theta(\bar{x}) d\bar{x} \stackrel{iii}{=} \int_{\mathbb{R}^n} \frac{d}{d\theta} f_\theta(\bar{x}) d\bar{x} =$$

$$= \int_{\mathbb{R}^n} \frac{d}{d\theta} \cdot \ln f_\theta(\bar{x}) d\bar{x} = \frac{d}{d\theta} \cdot 1 = 0; \text{ então}$$

$$\left| \text{Cov}_\theta \left[T(\bar{x}), \frac{d}{d\theta} \ln f_\theta(\bar{x}) \right] \right|^2 \leq \text{VAR}_\theta T(\bar{x}) \cdot \text{Var} \left[\frac{d}{d\theta} \ln f_\theta(\bar{x}) \right]$$

$$\boxed{\text{VAR}_\theta T(\bar{x}) \geq \frac{[\psi'(\theta)]^2}{E \left[\left(\frac{d}{d\theta} \ln f_\theta(\bar{x}) \right)^2 \right]}}$$

→ Limite inferior de Cramer-Rão

$$\frac{d}{d\theta} f_\theta(\bar{x}) = \varphi'$$

$$\frac{\text{cov}(X,Y)}{\text{Var} Y} \leq \text{Var}_\theta X$$

Condições do problema

i) ψ é derivável,

ii) espaço amostral X não depende de θ

$$iii) \frac{d}{d\theta} \int_{\mathbb{R}^n} g(\bar{x}) f_\theta(\bar{x}) d\bar{x} =$$

$$\int g(\bar{x}) \frac{d}{d\theta} f_\theta(\bar{x}) d\bar{x}$$

$\frac{d}{d\theta}$ não sobre f_θ , mas sobre a integral

iv) $\text{VAR}_\theta T(\bar{x}) < \infty$

$$\text{VAR}_\theta \left[\frac{d}{d\theta} \ln f_\theta(\bar{x}) \right] < \infty$$

R

Condições de Regularidade

Tomando a expressão da probabilidade de star

$$\begin{aligned} \frac{\partial}{\partial \theta} E_{\theta} \left[\frac{1}{d\theta} \ln f_{\theta}(x) \right] &= 0 \quad \frac{d}{d\theta} \int \left(\frac{1}{d\theta} \ln f_{\theta}(x) \right) \cdot f_{\theta}(x) dx \\ &= \int_{\mathbb{R}^n} \frac{d^2}{d\theta^2} \ln f_{\theta}(x) \cdot f_{\theta}(x) dx + \int_{\mathbb{R}^n} \left(\frac{d}{d\theta} \ln f_{\theta}(x) \right)^2 f_{\theta}(x) dx \\ &= E \left[\frac{d^2}{d\theta^2} \ln f_{\theta}(x) \right] + E \left[\left(\frac{d}{d\theta} \ln f_{\theta}(x) \right)^2 \right] = 0 \end{aligned}$$

$$\text{VAR}_{\theta} T(x) \geq - \underbrace{\left[\psi'(\theta) \right]^2}_{E \left[\frac{d^2}{d\theta^2} \ln f_{\theta}(x) \right]} \quad \text{informação de Fisher}$$

Observação se $E T(x) = \theta$
então $\psi'(\theta) = 0$
Neste caso, $\text{VAR} T(x) \geq - \frac{1}{E \left[\frac{d^2}{d\theta^2} \ln f_{\theta}(x) \right]}$

Em que situação $\text{VAR}(T(x)) = -(\psi'(\theta))^2$ ou $\text{VAR} T(x) \geq - \frac{1}{I(\text{Fisher})}$? $I(\theta)$

$$\left\{ \text{Cov}_{\theta} \left[T(x), \frac{1}{d\theta} \ln f_{\theta}(x) \right] \right\}^2 = (\psi'(\theta))^2 = -\text{VAR}_{\theta} T(x) \cdot E \left[\frac{d^2}{d\theta^2} \ln f_{\theta}(x) \right]$$

correlação entre $T(x)$ e $\frac{1}{d\theta} \ln f_{\theta}(x)$ vamos chamar de $S_{\theta}(x)$

$$\frac{d}{d\theta} \ln f_{\theta}(x) = \alpha(\theta) T(x) + \beta - \underbrace{\alpha(\theta)(T(x) - \psi(\theta))}_{\text{relação linear perfeita}}$$

$$\alpha = \frac{\text{Cov}(T(x), S_{\theta}(x))}{\text{Var}(T(x))} = \frac{\psi'(\theta) I(\theta)}{[\psi'(\theta)]^2} = \frac{I(\theta)}{\psi'(\theta)}$$

$$C^* \text{ VAR}(T(x)) = - \frac{(\psi'(\theta))^2}{E \left[\frac{d^2}{d\theta^2} \ln f_{\theta}(x) \right]} = - \frac{(\psi'(\theta))^2}{I(\theta)}$$

Logo: $\frac{d}{d\theta} \ln f_{\theta}(x) = \alpha(\theta) (T(x) - \psi(\theta))$

53

Família exponencial: $f_{\theta}(x) \propto \exp \{ A(\theta)T(x) + C(\theta) + D(x) \}$

$T(x)$ estadística, suficiente, completa e minimal.

$$\frac{d}{d\theta} \int_{\mathbb{R}^n} f_{\theta}(x) dx = \int_{\mathbb{R}^n} (A'(\theta)T(x) + C'(\theta)) f_{\theta}(x) dx$$

$$= A'(\theta) \cdot E T(x) + C'(\theta) = 0$$

$$E T(x) = -\frac{C'(\theta)}{A'(\theta)} = \psi(\theta)$$

Problemas

8-5

1, 2, 6, 7, 8, 9

54